GUÍA DE SOLUCIÓN - RETO "CANCELADO"

Data Science e Inteligencia Artificial

¿Qué es esta guía?

Esta plantilla describe los elementos clave que su solución debe contener. No es un formato rígido: su creatividad y enfoque son bienvenidos. Esta es una brújula, no un mapa.

1. ANÁLISIS INICIAL DE LOS DATOS

Descripción:

Comience por explorar y entender la base de datos entregada. Esta fase establece el contexto para todo lo demás.

Elementos esperados:

- Número total de registros (publicaciones, comentarios, etc.)
- Dimensiones: columnas disponibles y tipos de datos
- Distribución temporal: ¿cuándo comienza y termina la actividad en los datos?
- Plataformas representadas (X, TikTok, Instagram, Foro anónimo)
- Tipos de publicaciones: originales, reposteos, comentarios, transcripciones
- Usuarios involucrados: verificados, nuevos, anónimos, presuntos bots
- Valores faltantes o anomalías evidentes en los datos

Preguntas guía:

- ¿Cuál es el volumen total de actividad?
- ¿Dónde se concentra la mayoría del ruido (qué plataforma, qué tipo de usuario)?
- ¿Hay períodos de calma o picos anormales de actividad?
- ¿Qué proporción de la evidencia viene de usuarios verificados vs. nuevos vs. anónimos?

Qué mostrar en el prototipo:

- Tablas resumen con conteos básicos (por plataforma, por tipo de usuario, por tipo de publicación)
- Gráficos de distribución temporal (línea de tiempo de actividad)
- Estadísticas descriptivas de variables numéricas (interacciones, antigüedad de cuentas, velocidad de viralización)

2. IDENTIFICACIÓN DE PATRONES Y ANOMALÍAS

Descripción:

Aquí empieza el análisis real. Use Data Science para descubrir qué características diferencian evidencia confiable de manipulada, falsa o reciclada.

Patrones a explorar:

- Velocidad de viralización: ¿Qué tan rápido se propaga cada publicación? ¿Es normal o sospechosa?
- Similitud de contenido: ¿Hay textos casi idénticos pero de cuentas diferentes (reciclaje)?
- Coordinación de cuentas: ¿Hay grupos de usuarios que siempre postean juntos o a intervalos sospechosos?
- Perfil del usuario: ¿Es una cuenta verificada, nueva, bot sospechoso o fan antiguo? ¿Cuál es su historial?
- Antigüedad de cuenta: ¿Cuentas creadas justo antes del escándalo son más sospechosas?
- Corroboraciones independientes: ¿Otros usuarios sin conexión aparente cuentan lo mismo?
- Interacciones vs. antigüedad: ¿Una cuenta nueva con pocas interacciones súbitamente viraliza contenido?
- Cambios en el patrón de actividad: ¿Usuarios suelen postear sobre ciertos temas pero de repente cambian?

Técnicas de Data Science sugeridas:

- Análisis de similaridad textual (cosine similarity, TF-IDF) para detectar contenido reciclado
- Clustering (K-means, DBSCAN) para identificar grupos de usuarios o publicaciones similares
- Análisis de redes (graph analysis) para detectar coordinación entre cuentas
- Time series analysis para identificar picos y anomalías temporales
- Estadística descriptiva y outlier detection (IQR, Z-score) para hallazgos rápidos

Qué mostrar en el prototipo:

- Heatmaps o gráficos de correlación entre variables sospechosas
- Clusters visualizados (scatter plots, dendrogramas)
- Comparación lado a lado de textos similares (para detectar reciclaje)
- Gráficos temporales destacando anomalías detectadas
- Matriz de similaridad o redes de coordinación entre cuentas

3. METODOLOGÍA UTILIZADA

Descripción:

Documenten el camino que tomaron: qué pasos siguieron, en qué orden, y por qué. Esto no debe ser un párrafo largo; puede ser un flujo visual o una lista.

Elementos esperados:

- 1. Carga y limpieza de datos: ¿Qué valores faltantes manejaron? ¿Qué registros descartaron y por qué?
- 2. Exploración y análisis descriptivo: ¿Qué hallazgos iniciales obtuvieron?
- 3. Ingeniería de features: ¿Crearon nuevas variables a partir de las originales? (ej: ratio de interacciones/antigüedad)
- 4. Modelado o algoritmos: ¿Qué técnicas aplicaron? (ej: modelo de clasificación, regresión, clustering)
- 5. Validación: ¿Cómo verificaron que su solución funciona?
- 6. Prototipo: ¿Cómo presentaron los resultados de forma visual/interactiva?

Qué mostrar en el prototipo:

- Un diagrama de flujo o pipeline que muestre el proceso paso a paso
- Breve descripción de cada etapa (puede estar junto a los resultados)

4. USO DE DATA SCIENCE Y/O INTELIGENCIA ARTIFICIAL

Descripción:

Este reto exige que vayan más allá de gráficos: deben usar herramientas de Data Science o IA para automatizar la detección de anomalías y generar veredictos.

Enfoques posibles:

- Enfoque 1 (Supervised): Entrenar un modelo de clasificación para etiquetar publicaciones como 'confiable' vs. 'sospechosa'.
- Enfoque 2 (Unsupervised): Usar clustering para agrupar publicaciones similares y marcar los grupos más sospechosos.
- Enfoque 3 (Hybrid): Combinar reglas heurísticas con un modelo ML que ajuste pesos.
- Enfoque 4 (LLM): Usar un modelo de lenguaje para detectar inconsistencias o similitudes semánticas.

Qué mostrar en el prototipo:

- El modelo o algoritmo en acción: ingreso de datos → procesamiento → resultado automatizado
- Métricas de desempeño (si aplica): precisión, recall, F1-score
- Ejemplos reales de predicciones correctas e incorrectas

5. NIVEL O INDICADOR DE CONFIABILIDAD

Descripción:

Este es el 'veredicto' final. Cada publicación debe tener una puntuación o etiqueta clara.

Opciones de representación:

- Semáforo: Rojo (no confiable), Amarillo (dudoso), Verde (confiable)
- Escala numérica: 0 a 100
- Etiquetas categóricas: 'Verificado', 'Probablemente Cierto', 'Dudoso', etc.
- Combinación: Etiqueta + Puntuación + Barra visual

Criterios que deben alimentar el indicador:

- Antigüedad y verificación de la cuenta del autor
- Velocidad de viralización
- Similaridad con contenido anterior
- Corroboraciones independientes
- Patrones de la cuenta
- Características del texto

Qué mostrar en el prototipo:

- Para cada publicación: indicador visual + número/etiqueta
- Leyenda clara explicando qué significa cada color o etiqueta
- Ejemplos: mostrar 3-5 publicaciones reales con sus veredictos

6. PROTOTIPO FUNCIONAL

Descripción:

El análisis debe convertirse en algo que el usuario pueda usar. No necesita ser perfecto visualmente, pero debe ser funcional y claro.

Opciones de prototipo (elige una o combina):

- Dashboard: Panel que muestre métricas, gráficos y listado de publicaciones
- Interfaz web: Input → Procesa → Output (muestra confiabilidad + razones)
- Timeline interactiva: Cómo se propaga el rumor en el tiempo
- Análisis de redes: Grafo de cuentas conectadas, coloreadas por sospecha
- Reporte descargable: PDF o CSV con todos los análisis

Requisitos mínimos:

- Entrada de datos: El sistema debe leer la base de datos entregada
- Procesamiento: Aplicar limpieza, features engineering y el modelo elegido
- Salida clara: Mostrar resultados de forma visual y ordenada
- Interactividad (si el tiempo lo permite): Filtros, búsqueda, tooltips

Herramientas recomendadas:

- Python + Streamlit: Rápido para dashboards funcionales
- Python + Plotly + HTML: Visualizaciones interactivas personalizadas
- React/Vue + Node.js: Si prefieren un backend robusto
- Power BI o Tableau: Si dominan estas plataformas
- Google Sheets + AppScript: Opción más accesible

7. EXPLICACIÓN DE LOS RESULTADOS

Descripción:

No basta con un número. Deben explicar POR QUÉ se asignó cada veredicto. Esto es IA explicable (XAI).

Elementos esperados:

- Para cada publicación flagrada, mostrar las razones específicas
- Desglose de variables: mostrar qué factores influyeron en la decisión

- Importancia de features: si usan ML, mostrar qué variables tuvieron más peso
- Comparaciones: mostrar esta publicación vs. una típicamente confiable

Qué mostrar en el prototipo:

- Al hacer clic en cada publicación, mostrar desglose de la decisión
- Gráfico de barras horizontal mostrando contribución de cada variable
- Texto explicativo en lenguaje natural
- Ejemplos contrastantes: comparar con publicaciones confiables

8. CONCLUSIONES

Descripción:

Resuman sus hallazgos principales y lo que significan para resolver el caso real.

Elementos esperados:

- Hallazgo principal: ¿El escándalo es real o fabricado? ¿Cuál es el nivel de certeza?
- Patrones identificados: ¿Qué diferenció lo confiable de lo manipulado?
- Actores principales: ¿Quiénes fueron los impulsores? ¿Había coordinación?
- Recomendaciones: ¿Qué debería hacer la plataforma o las marcas?
- Limitaciones: ¿Qué no pudieron analizar?
- Próximos pasos: ¿Cómo debe actuar la empresa? ¿Qué paso a seguir le recomiendan? ¿Deberían renovarle el patrocinio?

Qué mostrar en el prototipo:

- Sección 'Resumen Ejecutivo' o 'Key Findings' clara y visual
- Números cuantitativos con los hallazgos principales
- Recomendación final destacada

CHECKLIST FINAL

Antes de presentar, verifiquen que su solución incluya:

- ☐ Análisis exploratorio de datos completo
- ☐ Identificación clara de patrones y anomalías
- ☐ Aplicación de técnicas de Data Science o IA
- ☐ Indicador de confiabilidad (semáforo, puntuación, o etiqueta)
- ☐ Prototipo funcional en pantalla
- ☐ Explicación clara de los resultados (IA explicable)
- ☐ Conclusiones y recomendaciones bien fundamentadas
- ☐ Evidencia de que los 4 integrantes aportaron al resultado

RECORDATORIO FINAL

- ✓ Cada equipo tiene 4 integrantes de semestres diferentes: asegúrense de que todos aporten.
- ✓ Creen nuevas variables a partir de los datos disponibles, no solo muestren los que llegan.
- ✓ El prototipo no necesita ser visualmente perfecto, pero sí funcional y claro.
- ✓ Expliquen sus decisiones: ¿por qué eligieron ese modelo? ¿Por qué esos features?
- ✓ Tendrán 6 minutos en el pitch: practiquen contar su historia de forma concisa.
- ✓ Si se quedan sin tiempo, prioricen análisis sólido + prototipo funcional.

¡Mucho éxito! 🚀